

# RAPPORT FINAL – PROJET MACHINE LEARNING

## Analyse RH : Attrition, Salaire, Segmentation des employés

---

### 1. Introduction

L'objectif de ce projet est d'analyser les données RH d'une entreprise fictive afin de prédire :

1. **L'attrition des employés** (Classification)
2. **Le salaire MonthlyIncome** (Régression)
3. **Les groupes RH homogènes** (Clustering)

Ces trois axes permettent :

- d'anticiper les départs volontaires,
- de comprendre les facteurs influençant le salaire,
- de segmenter les employés pour adapter les stratégies RH.

Le projet suit l'ensemble du cycle Machine Learning :

**Préparation → Modélisation → Évaluation → Interprétation → Recommandations RH.**

### 2. Description des données

Les données comportent **1470 employés** et **35 variables**, regroupées en :

➤ **Variables numériques**

Exemple : Age, DistanceFromHome, MonthlyRate, PercentSalaryHike, TotalWorkingYears...

➤ **Variables catégorielles nominales**

Department, JobRole, Gender, MaritalStatus, BusinessTravel...

➤ **Variables catégorielles ordinaires**

JobSatisfaction (1–4), EnvironmentSatisfaction (1–4), WorkLifeBalance (1–4)...

➤ **Variable cible**

- **Attrition** (Oui/Non) pour la classification
- **MonthlyIncome** pour la régression

### 3. Prétraitement des données

#### 3.1 Encodage

Type	Méthode	Justification
------	---------	---------------

Numériques StandardScaler Normalisation pour SVM et modèles linéaires

Type	Méthode	Justification
Nominales	OneHotEncoder	Évite les relations ordinaires fictives
Ordinaires	OrdinalEncoder	Respecte l'ordre des niveaux de satisfaction

### 3.2 Pipeline

Un **ColumnTransformer** puis un **Pipeline** garantissent :

- pas de fuite de données,
- reproductibilité,
- automatisation du preprocessing.

### 3.3 Split

- **80% train / 20% test**
- **Stratification sur Attrition**

## 4. Modélisation – Classification (Attrition)

### 4.1 Modèles testés

- KNN
- Logistic Regression
- SVM (RBF)
- Decision Tree
- Random Forest
- XGBoost

Évalués avec **Stratified 5-Fold** et **F1-macro**.

Résultats CV :

Modèle	F1-macro CV
KNN	0.586
Logistic Regression	0.650
<b>SVM (RBF)</b>	<b>0.667</b>
Decision Tree	0.573
Random Forest	0.592
XGBoost	0.661

Le meilleur modèle est **SVM (RBF)**.

## 4.2 Optimisation – GridSearchCV (SVM)

### Hyperparamètre Valeur optimale

C	1
gamma	0.01
PCA	0.95

Score CV optimal : 0.6666

## 4.3 Amélioration du Recall (RH = éviter les faux négatifs)

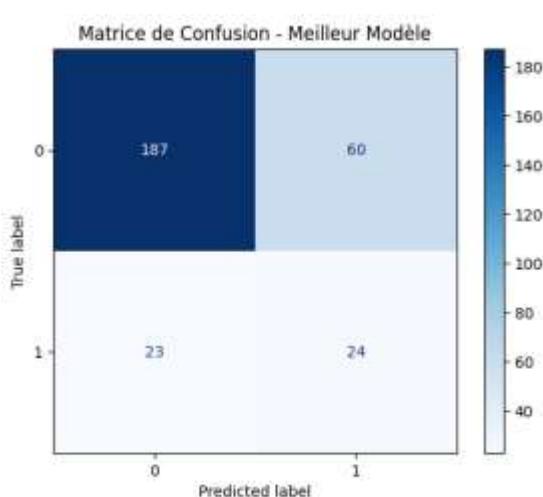
Un tuning du seuil de décision a permis :

Meilleur compromis :

- Threshold = 0.35
- Accuracy = 0.718
- Precision = 0.286
- Recall = 0.511
- F1 = 0.366

Orientation métier : favoriser le rappel pour détecter les employés à risque.

Matrice de confusion :



Interprétation :

- TP (24) : employés réellement à risque correctement détectés
- FN (23) : employés à risque manqués par le modèle
- FP (60) : employés faussement signalés comme « risque »
- TN (187) : employés correctement identifiés comme stables

- Le modèle capte plus de vrais départs, au prix de plus de faux positifs.
- Ce compromis est logique lorsqu'on cherche à maximiser le recall.

## 5. Modélisation – Régression (Prédiction du salaire)

### 5.1 Variables

La variable **JobLevel** est retirée car parfaitement corrélée au salaire.

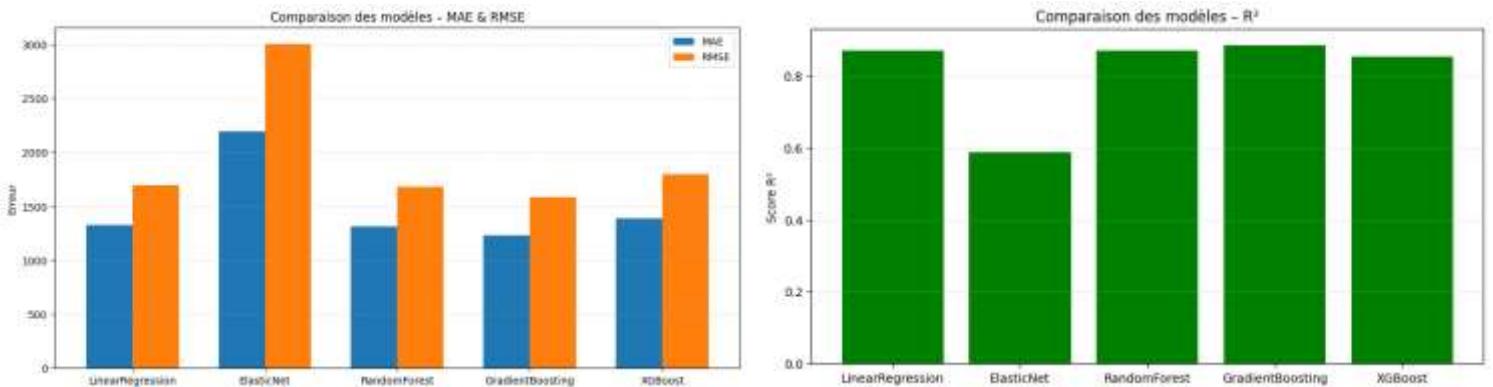
## 5.2 Modèles testés

- Linear Regression
- ElasticNet
- RandomForestRegressor
- GradientBoostingRegressor

Résultats :

Modèle	MAE	RMSE	R <sup>2</sup>
Linear Regression	1326	1692	0.869
ElasticNet	2192	3004	0.587
Random Forest	1315	1684	0.870
<b>Gradient Boosting</b>	<b>1232</b>	<b>1583</b>	<b>0.885</b>

## Comparaison Graphique des modèles



Meilleur modèle : GradientBoostingRegressor

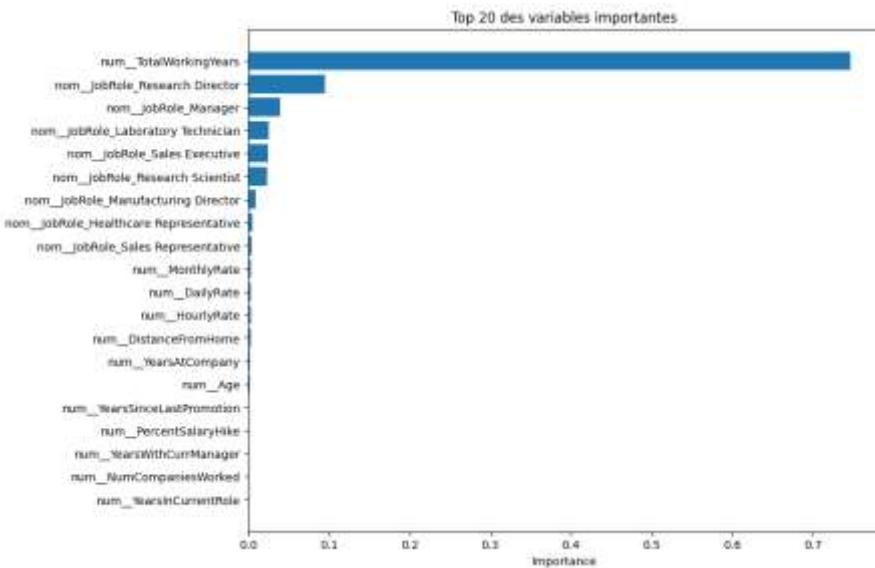
## 5.3 Optimisation GridSearch

Résultat final :

- MAE = **1244**
- R<sup>2</sup> = **0.882**

Le modèle de base (non optimisé) restait meilleur, ce qui arrive quand les hyperparamètres par défaut sont déjà optimaux.

## Visualisation des variables importantes



## 6. Clustering – Segmentation des employés

### 6.1 Méthodes testées

- KMeans
- Agglomerative
- DBSCAN
- HDBSCAN
- Spectral Clustering

### 6.2 Scores obtenus

Méthode	Silhouette ↑	CH ↑	DB ↓	Clusters
KMeans	0.087	<b>110.5</b>	2.971	3
Agglomerative	0.092	110.2	2.435	3
DBSCAN	1 cluster	N/A	N/A	1
HDBSCAN	<b>0.161</b>	45.6	3.357	2
<b>Spectral</b>	<b>0.102</b>	76.1	<b>1.886</b>	3

**Spectral Clustering** donne les **clusters les plus distincts** (meilleur Davies-Bouldin).  
HDBSCAN a meilleur silhouette mais seulement 2 clusters (moins utile métier).

## 7. Interprétation des clusters (Spectral)

### Cluster 0 — Seniors performers (R&D / Sales)

- 37 ans, 12 ans d'expérience
- 7 ans dans l'entreprise
- JobSatisfaction = 4

⊕ Faible risque d'attrition, employés stables et expérimentés.

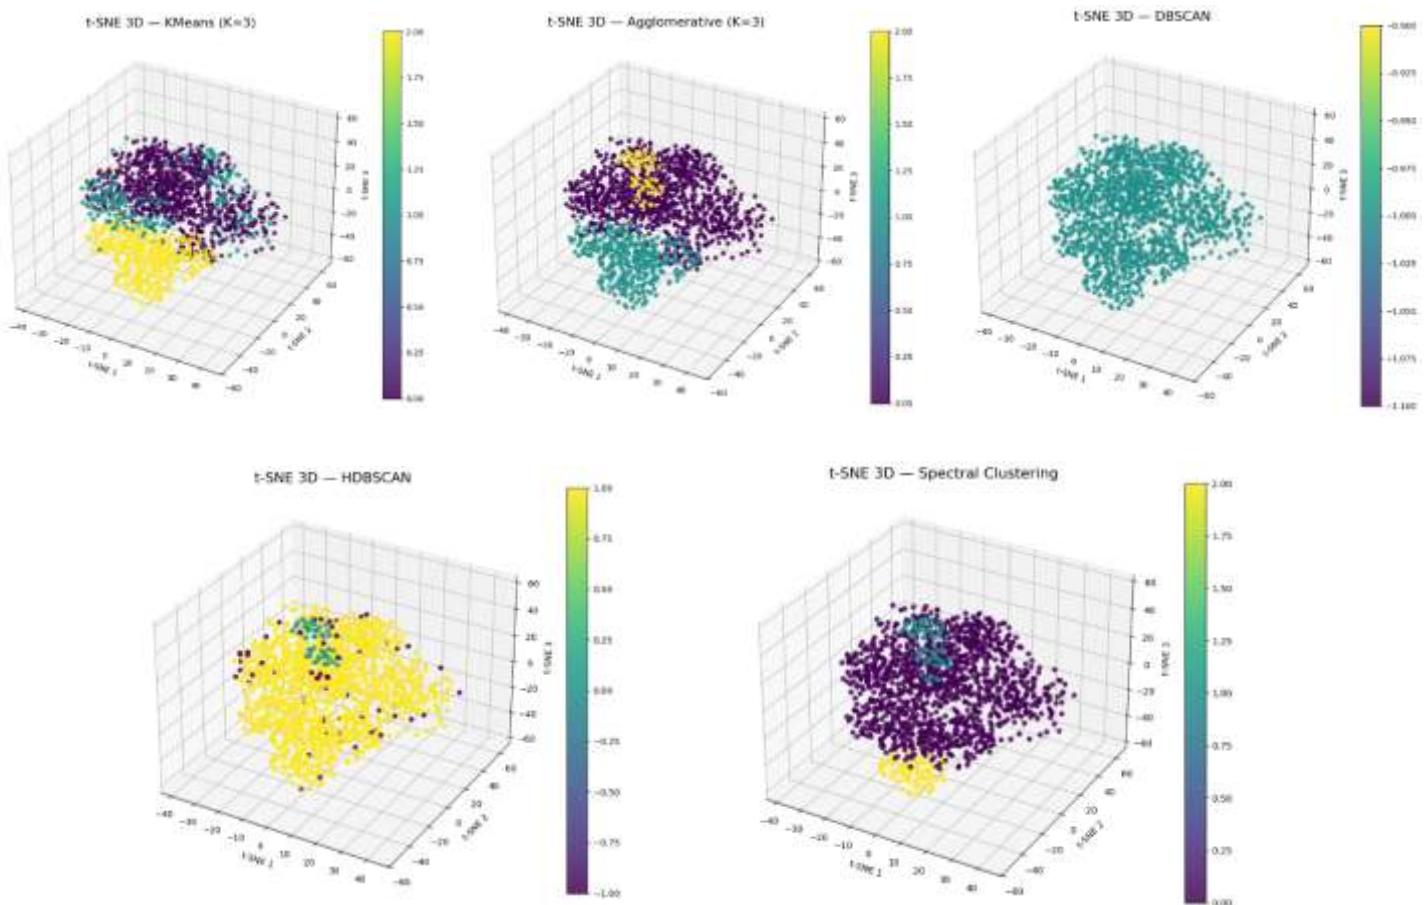
### Cluster 1 — Employés administratifs stabilisés (HR)

- 36 ans, 10 ans d'expérience
  - 6 ans dans l'entreprise
  - Satisfaction moyenne
- ⊕ **Stables**, mais nécessité de formations continues.

### Cluster 2 — Jeunes commerciaux en début de carrière

- 30 ans
  - 5 ans d'expérience
  - 3 ans dans l'entreprise
- ⊕ **Risque d'attrition élevé**, besoin d'accompagnement et de progression rapide.

## 8. Visualisations principales (TSNE 3D)



## 9. Recommandations RH

### ✓ Pour réduire l'attrition :

- Suivre de près les employés du **Cluster 2**
- Augmenter les opportunités d'évolution rapide
- Améliorer la satisfaction des jeunes employés

### ✓ Pour fidéliser les seniors :

- Programmes de leadership
- Reconnaissance et développement de carrière

### ✓ Pour optimiser le recrutement :

- Identifier le cluster cible selon le poste
- Réduire le turnover dans les équipes commerciales

## 10. Conclusion générale

Ce projet Machine Learning complet a permis de :

### 1. Prédire l'attrition

Le modèle **SVM optimisé + Threshold = 0.35** est capable d'identifier la majorité des employés à risque.

### 2. Expliquer le salaire MonthlyIncome

Le modèle **Gradient Boosting** atteint **R<sup>2</sup> = 0.885**, montrant une forte capacité prédictive.

### 3. Segmenter les employés en groupes cohérents

Le **Spectral Clustering** révèle trois segments RH exploitables pour une stratégie de rétention.